

1 Grundbegriffe

Definition Wahrscheinlichkeitraum
Ein Wahrscheinlichkeitraum ist ein Tupel $(\Omega, \mathcal{F}, \mathbb{P})$: <ul style="list-style-type: none">Die Menge Ω nennen wir Grundraum. Ein $\omega \in \Omega$ nennen wir Elementarereignis.$\mathcal{F} \subseteq \mathbb{P}(\Omega)$ ist eine Sigma-Algebra.\mathbb{P} ist ein Wahrscheinlichkeitsmass definiert auf (Ω, \mathcal{F}). Dabei ist $A \subseteq \Omega$ ein Ereignis.

1.1 Sigma-Algebra

Eine Sigma-Algebra $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ hat folgende Eigenschaften:

- 1. $\Omega \in \mathcal{F}$
- 2. $A \in \mathcal{F} \implies A^c \in \mathcal{F}$
- 3. $A_1, A_2, \dots \in \mathcal{F} \implies \bigcup_{i=1}^\infty A_i \in \mathcal{F}$
- 4. $\emptyset \in \mathcal{F}$
- 5. $A_1, A_2, \dots \in \mathcal{F} \implies \bigcap_{i=1}^\infty A_i \in \mathcal{F}$
- 6. $A, B \in \mathcal{F} \implies A \cup B \in \mathcal{F}$
- 7. $A, B \in \mathcal{F} \implies A \cap B \in \mathcal{F}$

De-Morgan Regel
$(\bigcup_{i=1}^\infty A_i)^c = \bigcap_{i=1}^\infty (A_i)^c$

1.2 Wahrscheinlichkeitsmass

Ein Wahrscheinlichkeitsmass \mathbb{P} ist eine Abbildung $\mathbb{P} : \mathcal{F} \mapsto [0, 1], A \mapsto \mathbb{P}[A]$ mit den Eigenschaften:

- 1. $\mathbb{P}[\Omega] = 1$ und $\mathbb{P}[\emptyset] = 0$
- 2. $\mathbb{P}[A] = \sum_{i=1}^\infty \mathbb{P}[A_i]$, falls $A = \bigsqcup_{i=1}^\infty A_i$
- 3. $\mathbb{P}[A^c] = 1 - \mathbb{P}[A]$
- 4. $\mathbb{P}[A \cup B] = \mathbb{P}[A] + \mathbb{P}[B] - \mathbb{P}[A \cap B]$
- 5. $A \subseteq B \implies \mathbb{P}[A] \leq \mathbb{P}[B]$ (Monotonie)
- 6. $\mathbb{P}[\bigcup_{i=1}^\infty A_i] \leq \sum_{i=1}^\infty \mathbb{P}[A_i]$ (Union Bound)
- 7. Falls A_1, \dots, A_n paarweise disjunkt, so gilt:

$$\mathbb{P}[A_1 \cup \dots \cup A_n] = \mathbb{P}[A_1] + \dots + \mathbb{P}[A_n]$$

Fast sichere Ereignisse
Wir sagen A tritt fast sicher (f.s.) ein, falls $\mathbb{P}[A] = 1$.

1.3 Bedingte Wahrscheinlichkeiten

Defintion Bedingte Wahrscheinlichkeit
$\mathbb{P}[A B] = \frac{\mathbb{P}[A \cap B]}{\mathbb{P}[B]}, \text{ wobei } \mathbb{P}[B] > 0$

Sei im folgenden nun $B_1, \dots, B_n \in \mathcal{F}$ eine **Partition von Ω** mit $\mathbb{P}[B_i] > 0$ für alle $1 \leq i \leq n$. Dann gilt:

Totale Wahrscheinlichkeit
$\forall A \in \mathcal{F} \quad \mathbb{P}[A] = \sum_{i=1}^n \mathbb{P}[A B_i] \mathbb{P}[B_i]$

Satz von Bayes
$\mathbb{P}[B_i A] = \frac{\mathbb{P}[A B_i] \mathbb{P}[B_i]}{\mathbb{P}[A]} = \frac{\mathbb{P}[A B_i] \mathbb{P}[B_i]}{\sum_{k=1}^n \mathbb{P}[A B_k] \mathbb{P}[B_k]}$

Wobei $\mathbb{P}[A] > 0$ gelten muss.

1.4 Unabhängigkeit von Ereignissen

Zwei Ereignisse $A, B \in \mathcal{F}$ sind unabhängig, falls gilt:

$$\mathbb{P}[A \cap B] = \mathbb{P}[A] \cdot \mathbb{P}[B] \text{ oder } \mathbb{P}[A|B] = \mathbb{P}[A]$$

- Falls $\mathbb{P}[A] \in \{0, 1\}$ (Indikatorvariabel), dann ist A zu jedem Ereignis unabhängig.
- Wenn A, B unabhängig sind, dann sind auch A, B^c unabhängig.

Unabhängigkeit von mehreren Ereignissen
$A_1, \dots, A_n \in \mathcal{F}$ sind unabhängig, falls: $\forall I \subseteq \{1, \dots, n\} \quad \mathbb{P}[\bigcap_{i \in I} A_i] = \prod_{i \in I} \mathbb{P}[A_i]$

2 Zufallsvariablen

Definition Gewichtsfunktion
$p_X : \mathbb{R} \mapsto [0, 1] : p_X(x) = \mathbb{P}[X = x] = \mathbb{P}[\{\omega X(\omega) = x\}]$

Es gilt:
$$\sum_{x \in \mathcal{W}(X)} p_X(x) = 1 \quad \text{und} \quad \forall x \in \mathcal{W}_X : 0 \leq p_X(x) \leq 1$$

Definition Verteilungsfunktion
$F_X : \mathbb{R} \mapsto [0, 1] \quad \forall x \in \mathbb{R} \quad F_X(x) = \mathbb{P}[X \leq x]$

- $F_X(x) = \int_{-\infty}^x f_X(x)dx$ bzw. $F_X(x) = \sum_{y \in \mathcal{W}_X, y \leq x} p(y)$
- $a < b \implies \mathbb{P}[a \leq X \leq b] = F_X(b) - F_X(a)$
- F ist monoton wachsend
- F ist rechtsstetig, d.h. $\lim_{t \rightarrow 0} F(x+t) = F(x)$
- $\lim_{x \rightarrow -\infty} F_X(x) = 0$ und $\lim_{x \rightarrow \infty} F_X(x) = 1$
- Median berechnen: x ist Median $\iff F_X(x) = 0.5$

2.1 Unabhängigkeit von ZV

X_1, \dots, X_n sind unabhängig, ist äquivalent zu: <ul style="list-style-type: none">• Diskreter Fall: $p(x_1, \dots, x_n) = p_{X_1}(x_1) \cdot \dots \cdot p_{X_n}(x_n)$• Stetiger Fall: $f(x_1 \dots x_n) = f_{X_1}(x_1) \cdot \dots \cdot f_{X_n}(x_n)$• $F_{X_1, \dots, X_n}(x_1 \dots x_n) = F_{X_1}(x_1) \cdot \dots \cdot F_{X_n}(x_n)$• Für alle $\phi_1, \dots, \phi_n : \mathbb{R} \mapsto \mathbb{R}$ gilt:$\mathbb{E}[\phi_1(x_1) \cdot \dots \cdot \phi_n(x_n)] = \mathbb{E}[\phi_1(x_1)] \cdot \dots \cdot \mathbb{E}[\phi_n(x_n)]$
--

X_1, X_2, \dots ist **unabhängig und identisch verteilt (uiv.)**, falls $\forall i, j \quad F_{X_i} = F_{X_j}$ gilt. Seien X_1, \dots, X_n (diskret) unabhängig und $g_i : \mathbb{R} \rightarrow \mathbb{R}$. Dann sind auch $g_1(X_1), \dots, g_n(X_n)$ unabhängig.

2.2 Diskrete Zufallsvariablen

Definition diskrete ZV
Eine ZV X heisst diskret, falls $\exists W \subset \mathbb{R}$ endlich oder abzählbar, so dass $X \in W$. Falls Ω endlich oder abzählbar ist, dann ist X immer diskret.

2.3 Diskrete Verteilungen

(Diskrete) Gleichverteilung (Laplace)
$\mathcal{W} = \{x_1, \dots, x_N\}. \mathbb{P}[X = x_i] = \frac{1}{N} \text{ und } \mathbb{E}[X] = \frac{\sum_{i=1}^N x_i}{N}$

Bernoulli-Verteilung
Hat nur die Ereignisse $\{0, 1\}$. $X \sim \text{Ber}(p)$ $\mathbb{P}[X = 0] = 1 - p \text{ und } \mathbb{P}[X = 1] = p$ $\mathbb{E}[X] = p \text{ und } \text{Var}[X] = p(1 - p)$

Binomialverteilung
Wiederholung von Bernoulli-Exp. $X \sim \text{Bin}(n, p)$
$\forall k \in \{0, \dots, n\} \quad \mathbb{P}[X = k] = \binom{n}{k} \cdot p^k \cdot (1-p)^{n-k}$
$\mathbb{E}[X] = np \quad \text{und} \quad \text{Var}[X] = np(1-p)$
Falls $X \sim \text{Bin}(n_x, p)$ und $Y \sim \text{Bin}(n_y, p)$ unabhängig sind, dann gilt für $Z := X + Y$, dass $Z \sim \text{Bin}(n_x + n_y, p)$.

Negative Binomialverteilung
Warten auf den r -ten Erfolg von Bernoulli Experimenten (Falls $r = 1$, so ist $X \sim \text{Geo}(p)$). $X \sim \text{NB}(r, p)$
$\mathbb{P}[X = k] = \binom{k-1}{r-1} p^r (1-p)^{k-r}$
$\mathbb{E}[X] = \frac{r}{p} \quad \text{und} \quad \text{Var}[X] = \frac{r \cdot (1-p)}{p^2}$
$(X_i)_{i=1}^r \sim \text{Geo}(p)$ und unabh. $\Rightarrow X := X_1 + \dots + X_r \sim \text{NB}(r, p)$.

Geometrische Verteilung
Beschreibt das 1. Auftreten eines Erfolges. $X \sim \text{Geom}(p)$
$\mathbb{P}[X = k] = (1-p)^{k-1} \cdot p \quad F_X(k) = \mathbb{P}[X \leq k] = 1 - (1-p)^k$
$\mathbb{E}[X] = \frac{1}{p} \quad \text{und} \quad \text{Var}[X] = \frac{1-p}{p^2}$
Gedächtnislosigkeit: $\mathbb{P}[X > y + x X > x] = \mathbb{P}[X > y]$

Hypergeometrische Verteilung
Urne mit n Elementen, davon r vom Typ 1 und $n-r$ vom Typ 2. Ziehe m Elemente daraus, dann beschreibt X die Anzahl Elemente vom Typ 1.
$\mathbb{P}[X = k] = \frac{\binom{r}{k} \binom{n-r}{m-k}}{\binom{n}{m}} \quad \text{für } k \in \{0, 1, \dots, \min(m, r)\}$
$\mathbb{E}[X] = m \cdot \frac{r}{n} \quad \text{und} \quad \text{Var}[X] = m \cdot \frac{r}{n} \left(1 - \frac{r}{n}\right) \frac{n-m}{n-1}$

Cauchy-Verteilung: Sind $Y, Z \sim \mathcal{N}(0, 1)$ unabhängig, so ist $X := Y/Z$ Cauchy-verteilt. (EW und Varianz existieren nicht!)
 $f_X(x) = \frac{1}{\pi} \cdot \frac{1}{1+x^2} \quad \text{und} \quad F_X(x) = \frac{1}{\pi} + \frac{1}{\pi} \cdot \arctan(x)$

Poisson-Verteilung
Annäherung an die Binomialvert. (0-1-Exp.) für grosse n und kleine p (d.h. rare Ereignisse). $X \sim \text{Poisson}(\lambda)$
$\forall k \in \mathbb{N}, \lambda > 0 \quad \mathbb{P}[X = k] = \frac{\lambda^k}{k!} \cdot e^{-\lambda}$
$\mathbb{E}[X] = \lambda \quad \text{und} \quad \text{Var}[X] = \lambda$
Sind X und Y unabhängige ZV mit $X \sim \text{Po}(\lambda_1)$ und $Y \sim \text{Po}(\lambda_2)$, dann gilt für $Z := X + Y \sim \text{Po}(\lambda_1 + \lambda_2)$.

2.4 Stetige Zufallsvariablen

Definition stetige ZV
Eine ZV X heisst stetig, wenn ihre Verteilungsfunktion F_X wie folgt geschrieben werden kann:
$\forall x \in \mathbb{R} \quad F_X(x) = \int_{-\infty}^x f(y) dy$
Die Verteilungsfunktion F_X sei stetig und stückweise C^1 . Dann ist X eine stetige ZV und $f(x) = F_X'(x)$.

Hierbei ist $f : \mathbb{R} \mapsto \mathbb{R}^+$ die **Dichtefunktion** von X . Es gilt:

$$\int_{-\infty}^{+\infty} f(y) dy = 1 \quad \text{und} \quad \forall x \in \mathbb{R} : f_X(x) \geq 0$$

Es gelten folgende Eigenschaften: $\mathbb{P}[a \leq x \leq b] = \mathbb{P}[a < x < b]$ und $\mathbb{P}[X \in [a, b]] = \mathbb{P}[X \in (a, b)]$
Zudem gilt für stetige ZV: $\mathbb{P}[\mathbf{X} = \mathbf{x}] = \mathbf{0}, \forall x \in W_x$

2.5 Stetige Verteilungen

(Stetige) Gleichverteilung
Jedes Ereignis hat die gleiche W'keit. $X \sim \mathcal{U}[a, b]$
$f_{a,b}(x) = \begin{cases} 0 & x \notin [a, b] \\ \frac{1}{b-a} & x \in [a, b] \end{cases}$
$F_{a,b}(x) = \int_{-\infty}^x f_{a,b}(t) dt = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & a \leq x \leq b \\ 1 & x > b \end{cases}$
$\mathbb{E}[X] = \frac{a+b}{2} \quad \text{und} \quad \text{Var}[X] = \frac{(a-b)^2}{12}$

Exponentialverteilung
Das stetige Gegenstück zur Geometrischen Verteilung (verwendet für Warte- & Überlebenszeiten). $X \sim \text{Exp}(\lambda)$
$f(x) = \begin{cases} 0 & x < 0 \\ \lambda \cdot e^{-\lambda x} & x \geq 0 \end{cases}$
$F(x) = \int_0^x f(t) dt = \begin{cases} 1 - e^{-\lambda \cdot x} & x \geq 0 \\ 0 & x < 0 \end{cases}$
$\mathbb{E}[X] = \frac{1}{\lambda} \quad \text{und} \quad \text{Var}[X] = \frac{1}{\lambda^2}$
Skalierung: Für $X \sim \text{Exp}(\lambda)$, $a > 0$ und $Y := aX$: $Y \sim \text{Exp}(\frac{\lambda}{a})$.
Wartezeit: $\forall x \geq 0 : \mathbb{P}[X > x] = 1 - F(x) = e^{-\lambda \cdot x}$
Gedächtnislosigkeit: $\mathbb{P}[X > y + x X > x] = \mathbb{P}[X > y]$

Normalverteilung
Additive Überlagerung einer großen Zahl von unabhängigen Einflüssen (Bsp: Messfehler). $X \sim \mathcal{N}(m, \sigma^2)$
$f_{m,\sigma}(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \cdot e^{-\frac{(x-m)^2}{2\sigma^2}}$
$\mathbb{E}[X] = m \quad \text{und} \quad \text{Var}[X] = \sigma^2$

\Rightarrow 68.27% der Werte liegen im Intervall $\mu \pm \sigma$, 95,45% in $\mu \pm 2\sigma$ und 99,73% in $\mu \pm 3\sigma$. Zudem gilt: $\mathbb{P}[X \in [\mu - z\sigma, \mu + z\sigma]] = 2\phi(z) - 1$

Sei $X_i \sim \mathcal{N}(m_i, \sigma_i^2)$ unabhängig , dann: $Z := (m_0 + \lambda_1 \cdot X_1 + \dots + \lambda_n \cdot X_n) \sim \mathcal{N}(m_0 + \lambda_1 \cdot m_1 + \dots + \lambda_n \cdot m_n, \lambda_1^2 \cdot \sigma_1^2 + \dots + \lambda_n^2 \cdot \sigma_n^2)$.

Standardnormalvert.: Sei $Z \sim \mathcal{N}(0, 1)$. Für eine normalverteilte ZV X gilt $X = m + \sigma \cdot Z \sim \mathcal{N}(m, \sigma^2)$.
 $\Rightarrow \mathbb{P}[X \leq x] = \mathbb{P}[Z \leq \frac{x-\mu}{\sigma}] = \phi(\frac{x-\mu}{\sigma})$
Ist $X \sim \mathcal{N}(\mu, \sigma^2)$, so ist $Y := e^X$ logarithmisch normalvert.

3 Erwartungswert und Varianz

Erwartungswert für diskrete ZV
$\mathbb{E}[X] = \sum_{x \in W} x \cdot \mathbb{P}[X = x] = \sum_{\omega \in \Omega} X(\omega) \cdot \mathbb{P}[\omega]$

Sei $\phi : \mathbb{R} \mapsto \mathbb{R}$ eine Abbildung. Falls die Summe wohldefiniert ist (abs. konv.), gilt: $\mathbb{E}[\phi(X)] = \sum_{x \in W} \phi(x) \cdot \mathbb{P}[X = x]$
Achtung: EW existiert nicht immer! (Summe muss abs. konv.)

Erwartungswert für stetige ZV

Falls die Verteilung von X absolut stetig ist, gilt:

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

\Rightarrow EW existiert nur, falls das Integral **absolut konvergiert!**
Sei $\phi: \mathbb{R} \mapsto \mathbb{R}$ eine Abbildung, sodass $\phi(x)$ eine Zufallsvariable ist. Es gilt: $\mathbb{E}[\phi(X)] = \int_{-\infty}^{\infty} \phi(x) f(x) dx$
Man kann den EW auch über die Verteilungsfunktion definieren:

$$\mathbb{E}[X] = \int_0^{\infty} (1 - F_X(x)) dx - \int_{-\infty}^0 F_X(x) dx$$

\Rightarrow Für ZV mit nicht-neg. Werten gilt: $\mathbb{E}[X] = \int_0^{\infty} (1 - F_X(x)) dx$.

3.1 Rechnen mit Erwartungswerten

- **Linearität:** Seien X, Z Zufallsvariablen mit $a, b \in \mathbb{R}$. Falls die Erwartungswerte wohldefiniert sind, gilt

$$\mathbb{E}[a \cdot X + b] = a \cdot \mathbb{E}[X] + b$$

- **Monotonie:** $X(\omega) \leq Y(\omega), \forall \omega \in \Omega \Rightarrow \mathbb{E}[X] \leq \mathbb{E}[Y]$
- **Mon. Stetigkeit:** $0 \leq X_1 \leq X_2 \leq \dots \Rightarrow \mathbb{E}[\lim_n X_n] = \lim_n \mathbb{E}[X_n]$
- **Satz von Lebesgue:** Sei X_1, X_2, \dots f.s. konv. Folge mit $|X_i(\omega)| \leq X(\omega)$ für ZV X mit $\mathbb{E}[X] < \infty$, dann: $\mathbb{E}[\lim_n X_n] = \lim_n \mathbb{E}[X_n]$
- Für paarweise disjunkte Ereignisse $(A_i)_{i=1}^n, \bigcup_{i=1}^n A_i = \Omega$ und $\forall A_i: \mathbb{P}[A_i] > 0$, gilt:

$$\mathbb{E}[X] = \sum_{i=1}^n \mathbb{E}[X|A_i] \cdot \mathbb{P}[A_i]$$

- **Multplikativität:** Falls X_1, \dots, X_n **unabhängig** $\Rightarrow \mathbb{E}[g_1(X_1) \cdot \dots \cdot g_n(X_n)] = \mathbb{E}[g_1(X_1)] \cdot \dots \cdot \mathbb{E}[g_n(X_n)]$
- **Extremwertformel:** Sei X eine diskrete ZV mit Werten in \mathbb{N} . Dann gilt folgende Identität (gilt auch analog für stetige ZV):

$$\mathbb{E}[X] = \sum_{n=1}^{\infty} \mathbb{P}[X \geq n]$$

- **Waldsche Identität:** Seien X_1, X_2, \dots, X_n uiv. ZV und N eine ZV mit Werten in \mathbb{N} . Dann gilt:

$$\mathbb{E}\left[\sum_{i=1}^N X_i\right] = \mathbb{E}[N] \cdot \mathbb{E}[X_1]$$

- **Alternativdefinition unabhängige ZV** Seien X_1, \dots, X_n diskrete ZV. Dann gilt: X_1, \dots, X_n sind unabhängig \iff Für jedes $\phi_1, \dots, \phi_n: \mathbb{R} \mapsto \mathbb{R}$ beschränkt, gilt:

$$\mathbb{E}[\phi_1(X_1) \cdot \dots \cdot \phi_n(X_n)] = \mathbb{E}[\phi_1(X_1)] \cdot \dots \cdot \mathbb{E}[\phi_n(X_n)]$$

3.2 Bedingter Erwartungswert

Bedingter Erwartungswert

$$\mathbb{E}[X|Y] = \frac{\mathbb{E}[I_A \cdot X]}{\mathbb{P}[Y]} = \sum_{x \in X(\Omega)} x \cdot \mathbb{P}[X = x|Y]$$

Eigenschaften:

- $\mathbb{E}[a_1 \cdot X_1 + a_2 \cdot X_2|A] = a_1 \cdot \mathbb{E}[X_1|A] + a_2 \cdot \mathbb{E}[X_2|A]$
- Ist X unabhängig von Y , so gilt: $\mathbb{E}[X|Y] = \mathbb{E}[X]$

Bedingt auf eine Partition

Sei $\mathcal{B} = (B_i)_{i \in I}$ eine Partition von Ω . Dann definieren wir die **Zufallsvariablen**:

$$\mathbb{E}[X|B](\omega) = \sum_{i \in I} \mathbb{E}[X|B_i] \cdot 1_{B_i}(\omega)$$

Eigenschaften:

- Totaler Erwartungswert: $\mathbb{E}[\mathbb{E}[X|\mathcal{B}]] = \mathbb{E}[X]$
- $\mathbb{E}[1_{B_i} \cdot \mathbb{E}[X|\mathcal{B}]] = \mathbb{E}[1_{B_i} \cdot X]$

Beispiel: Zwei Würfel werden geworfen. Sei $\Omega = \{1, 2, \dots, 6\}^2$ und $\mathbb{P}[(\omega_1, \omega_2)] = 1/36 \forall \omega \in \Omega$. Sei $Y :=$ "Augenzahl des 2. Würfels" und sei $\mathcal{B} = (B_i)_{i=1}^6$ wobei $B_i = \{Y = i\}$. Berechne $\mathbb{E}[Y|\mathcal{B}](2, 4)$.
 $\Rightarrow \mathbb{E}[Y|\mathcal{B}](2, 4) = \sum_{i=1}^6 \mathbb{E}[Y|B_i] \cdot 1_{B_i}(2, 4) = \mathbb{E}[Y|B_4] = \frac{\mathbb{E}[1_{Y=4} \cdot Y]}{\mathbb{P}[Y=4]} = \frac{4 \cdot \mathbb{P}[(1,4)] + 4 \cdot \mathbb{P}[(2,4)] + \dots + 4 \cdot \mathbb{P}[(6,4)]}{\mathbb{P}[Y=4]} = \frac{24/36}{1/6} = 4$

3.3 Varianz

Varianz

Sei X eine ZV sodass $\mathbb{E}[X^2] < \infty$.

$$\text{Var}[X] := \sigma_X^2 = \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

$$\text{Var}[X] = \begin{cases} \sum_{x \in W_X} (x - \mathbb{E}[X])^2 \cdot \mathbb{P}[X = x] & , X \text{ diskret} \\ \int_{-\infty}^{\infty} (x - \mathbb{E}[X])^2 \cdot f_X(x) dx & , X \text{ stetig} \end{cases}$$

Eigenschaften:

- $\text{Var}[a \cdot X + b] = a^2 \cdot \text{Var}[X]$
- X_1, \dots, X_n **unabhängig** $\Rightarrow \text{Var}[\sum_{i=1}^n X_i] = \sum_{i=1}^n \text{Var}[X_i]$
- Allgemein $(\text{Cov}(X_i, Y_i) = 0, \text{ wenn } X_i \text{ und } Y_i \text{ unabhängig})$:

$$\text{Var}\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \text{Var}[X_i] + 2 \cdot \sum_{i < j} \text{Cov}(X_i, Y_i)$$

3.4 Kovarianz

Definition Kovarianz

Sei X, Y zwei ZV mit $\mathbb{E}[X^2], \mathbb{E}[Y^2] < \infty$.

$$\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])] = \mathbb{E}[X \cdot Y] - \mathbb{E}[X] \cdot \mathbb{E}[Y]$$

Eigenschaften der Kovarianz:

- $\text{Cov}(X, X) = \text{Var}[X]$
- X, Y unabhängig $\implies \text{Cov}(X, Y) = 0$
- $\text{Cov}(X, Y) = \text{Cov}(Y, X)$
- $\text{Cov}(X, a \cdot Y + b) = a \cdot \text{Cov}(X, Y)$ und $\text{Cov}(X, b) = 0$
- $\text{Cov}(X, Y + Z) = \text{Cov}(X, Y) + \text{Cov}(X, Z)$
- $|\text{Cov}(X, Y)| \leq \sigma(X) \cdot \sigma(Y)$

Korrelation

$$\rho(X, Y) := \begin{cases} \frac{\text{Cov}(X, Y)}{\sigma(X) \cdot \sigma(Y)} & , \text{ falls } \sigma(X) \cdot \sigma(Y) > 0 \\ 0 & , \text{ sonst} \end{cases}$$

Korrelation misst den lin. Zshg. Es gilt $-1 \leq \rho(X, Y) \leq 1$.
Ist $\text{Cov}(X, Y) = 0$, so nennt man X und Y **unkorreliert**.
Es gilt: unabhängig \Rightarrow paarweise unabhängig \Rightarrow unkorreliert

3.5 Momente

Sei X eine Zufallsvariable und $p \in \mathbb{R}_+$. Wir definieren:

- das p -te absolute Moment von X durch $M_p := \mathbb{E}[|X|^p]$ (kann ∞ sein)
- falls $M_n < \infty$ für ein n , dann ist das n -te (rohe) Moment von X durch $m_n := \mathbb{E}[X^n]$ definiert.
- Das n -te zentralisierte Moment von X durch $\mu_n := \mathbb{E}[(X - \mathbb{E}[X])^n]$ definiert. (für $n = 2$ erhalten wir die Varianz)

Damit folgt sofort: $M_n < \infty$ für $n \in \mathbb{N} \Rightarrow |m_n| \leq M_n$.
Hat X eine Dichte f_X , dann gilt zudem für das absolute Moment:

$$M_p = \int_{-\infty}^{\infty} |x|^p f_X(x) dx$$

Gilt dann $M_n < \infty$ für ein $n \in \mathbb{N}$, dann können wir auch das n -te Moment per Integral bestimmen:

$$m_n = \int_{-\infty}^{\infty} x^n f_X(x) dx$$

und für diskrete ZV: $m_n = \sum_{i=1}^{\infty} x_i^n \cdot \mathbb{P}[X = x_i]$

4 Gemeinsame Verteilungen

Diskrete gemeinsame Verteilung
Seien X_1, \dots, X_n diskrete ZV wobei $X_i \in W_i$ für $W_i \subset \mathbb{R}$. Die gemeinsame Verteilung von X_1, \dots, X_n ist: $p(x_1, \dots, x_n) = \mathbb{P}[X_1 = x_1, \dots, X_n = x_n]$

Die **Randverteilung** ist definiert als $F_X(x) := \mathbb{P}[X \leq x] = \mathbb{P}[X \leq x, Y \leq \infty] = \lim_{y \rightarrow \infty} F(x, y)$ und die **Randdichte** erhalten wir durch “wegaddieren”: $p_X(x) = \sum_{y \in \mathcal{W}(Y)} p(x, y)$
Der **Erwartungswert** ist definiert als $(\phi : \mathbb{R}^n \rightarrow \mathbb{R})$:

$$\mathbb{E}[\phi(X_1, \dots, X_n)] = \sum_{x_1, \dots, x_n} \phi(x_1, \dots, x_n) \cdot p(x_1, \dots, x_n)$$

Stetige gemeinsame Verteilung
Falls die gemeinsame Verteilungsfunktion F von X_1, \dots, X_n (stetige ZV) sich schreiben lässt als $F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_n \dots dt_1$ für eine Funktion $f : \mathbb{R}^n \rightarrow [0, \infty)$, dann ist f die gemeinsame Dichte .

Es gilt: $\int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(t_1, \dots, t_n) dt_n \dots dt_1 = 1$
Seien X_1, \dots, X_n stetige ZV mit einer gemeinsamen Dichte f und $\phi : \mathbb{R}^n \mapsto \mathbb{R}$. Dann ist der **Erwartungswert** definiert als:

$$\mathbb{E}[\phi(X_1, \dots, X_n)] = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \phi(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_n \dots dx_1$$

Die **Randverteilung** ist definiert als $F_X(x) := \mathbb{P}[X \leq x] = \mathbb{P}[X \leq x, Y \leq \infty] = \lim_{y \rightarrow \infty} F(x, y)$ und die **Randdichte** erhalten wir durch “wegintegrieren”: $f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy$.

Bedingte Dichte, Verteilung und EW
Die bedingte Verteilung für zwei stetige ZV X, Y ist (gilt analog auch für diskrete ZV): $f_{X Y}(x y) := \frac{f(x, y)}{f_Y(y)}, \text{ für } f_Y(y) > 0 \text{ und } 0 \text{ sonst.}$ $\mathbb{P}[Y > t Y < a] = \frac{P[t < Y < a]}{P[Y < a]}$ $E[X_1 X_2](x_2) = \int x_1 f_{X_1 X_2}(x_1 x_2) dx_1$

4.1 Konvolution (Faltung)

Konvolution (Faltung)
Seien X und Y unabhängige kontinuierliche Zufallsvariabeln. Für die Dichte von $Z := X + Y$ gilt: $f_Z(z) = (f_X * f_Y)(z) = \int_{-\infty}^{\infty} f(x, z-x) dx \stackrel{\text{u.i.v.}}{=} \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(z-x) dx$ und für die Verteilung erhalten wir: $F_Z(z) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(x, v-x) dv dx = \int_{-\infty}^{\infty} F_X(z-x) f_Y(x) dx$

Für diskrete Zufallsvariablen gilt analog:

$$p_Z(z) = p_X(z) * p_Y(z) = \sum_{x \in \mathcal{W}(X)} p_X(x) \cdot p_Y(z - x)$$

Es gilt: $\text{Ber}(p) * \text{Ber}(p) = \text{Bin}(2, p)$, $\text{Bin}(n, p) * \text{Bin}(m, p) = \text{Bin}(n + m, p)$,
 $\text{Poi}(\lambda_1) * \text{Poi}(\lambda_2) = \text{Poi}(\lambda_1 + \lambda_2)$, $\text{Geo}(p) * \text{Geo}(p) = \text{NB}(2, p)$,
 $\text{NB}(r, p) * \text{NB}(s, p) = \text{NB}(r + s, p)$, $\mathcal{N}(0, 1) * \mathcal{N}(0, 1) = \mathcal{N}(0, 2)$ und
 $\mathcal{N}(\mu_1, \sigma_1^2) * \mathcal{N}(\mu_2, \sigma_2^2) = \mathcal{N}(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$
Beispiel: Seien X, Y unabh. und exp.vert. mit $\lambda > 0$, berechne f_Z von $Z := X + Y \Rightarrow f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx = \int_0^z \lambda e^{-\lambda x} \lambda e^{-\lambda(z-x)} dx = \int_0^z \lambda^2 e^{-\lambda z} dx = \lambda^2 z e^{-\lambda z}$, für $z \geq 0$. Wir sehen also $Z \sim \text{Ga}(2, \lambda)$.

5 Ungleichungen

Markov-Ungleichung
Sei X eine ZV die nur nichtnegative Werte annimmt, dann gilt für jedes $a > 0$: $\mathbb{P}[X \geq a] \leq \frac{\mathbb{E}[X]}{a}$ Sei $g : \mathcal{W}(X) \rightarrow [0, \infty)$ eine wachsende Funktion. Dann gilt sogar: $\mathbb{P}[X \geq a] \leq \frac{\mathbb{E}[g(X)]}{g(a)}$
Chebychev-Ungleichung
Wenn X eine ZV mit $\mathbb{E}[X^2] < \infty$ ist, dann gilt für jedes $a \geq 0$: $\mathbb{P}[X - \mathbb{E}[X] \geq a] \leq \frac{\text{Var}[X]}{a^2}$

Oder äquivalent: $\mathbb{P}[|X - \mathbb{E}[X]| \geq a \cdot \sqrt{\text{Var}[X]}] \leq \frac{1}{a^2}$

Jensen-Ungleichung
Sei X eine ZV und $\phi : \mathbb{R} \mapsto \mathbb{R}$ eine konvexe Funktion, dann gilt: $\phi(\mathbb{E}[X]) \leq \mathbb{E}[\phi(X)]$

\Rightarrow Somit gilt: $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$ und $\mathbb{E}[|X|] \leq \sqrt{\mathbb{E}[X^2]}$

6 Grenzwertsätze

Seien im folgenden X_1, \dots, X_n **u.i.v.** ZV (und somit $\mathbb{E}[X_i] = \mathbb{E}[X_j]$ und $\text{Var}[X_i] = \text{Var}[X_j]$ für $i, j \in \{1, \dots, n\}$).

Gesetz der grossen Zahlen
Sei $\mathbb{E}[X_i] < \infty$, so gilt (fast sicher): $\lim_{n \rightarrow \infty} \frac{X_1 + \dots + X_n}{n} = \mathbb{E}[X_i]$
Zentraler Grenzwertsatz
Sei $S_n := X_1 + \dots + X_n$, $\mu = \mathbb{E}[X_i]$ und $\sigma^2 = \text{Var}(X_i)$, so gilt: $\mathbb{P}\left[\frac{S_n - n \cdot \mu}{\sigma \sqrt{n}} \leq a\right] \xrightarrow{n \rightarrow \infty} \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^a e^{-\frac{x^2}{2}} dx$ für alle $a \in \mathbb{R}$, wobei Φ die Verteilungsfunktion der $\mathcal{N}(0, 1)$ -Verteilung ist.

Der zentrale Grenzwertsatz sagt aus, dass die Verteilung einer ZV $Z_n = \frac{S_n - n\mu}{\sigma \sqrt{n}}$ ungefähr wie die Verteilung von $\mathcal{N}(0, 1)$ aussieht, also $\mathbb{P}[Z_n \leq x] \approx \Phi(x)$ (für grosse n). Und somit auch $S_n \stackrel{\text{approx.}}{\sim} \mathcal{N}(n\mu, n\sigma^2)$. Zudem: $\lim_{n \rightarrow \infty} \mathbb{P}[a \leq Z_n \leq b] = \int_a^b \varphi(x) dx$

7 Random Walk

Definition Simple Random Walk: $0 < p < 1$ und $X_i = \{-1, 1\}$ und $\mathbb{P}[X_i = +1] = p$ bzw. $\mathbb{P}[X_i = -1] = 1 - p$.
Gambler's Ruin: Nehmen wir einen Simple Rand. Walk mit Anfangsposition $a \geq 0$. Das Spiel ist beendet, falls der Zocker ein Kontostand von N oder 0 erreicht. Sei $p_{win}(a) := \mathbb{P}$ ["Kontostand N erreicht von Startkapital a aus"] (wobei $0 < a < N$). Es gilt folgende Rekurrenz: $p_{win}(a) = p \cdot p_{win}(a + 1) + (1 - p) \cdot p_{win}(a - 1)$
Offensichtlich gilt: $p_{win}(0) = 0$ (bereits verloren) und $p_{win}(N) = 1$ (bereits gewonnen). Wir erhalten für $p_{win}(a)$ (und $1 - p_{win}(a)$ für Wahrscheinlichkeit von Ruin):

$$p_{win}(a) = \begin{cases} \frac{1 - (\frac{1-p}{p})^a}{1 - (\frac{1-p}{p})^N} & \text{wenn } p \neq (1 - p) \\ \frac{a}{N} & \text{wenn } p = (1 - p) = 1/2 \end{cases}$$

8 Induktive Statistik: Basics

Idee: Man fasst die Daten x_1, \dots, x_n auf als Realisierungen $X_1(\omega), \dots, X_n(\omega)$ von Zufallsvariablen X_1, \dots, X_n , und sucht dann (unter geeigneten Zusatzannahmen) Aussagen über die Verteilung von X_1, \dots, X_n . Die x_1, \dots, x_n werden *Stichprobe* genannt, das n ist der *Stichprobenumfang*.

8.1 Schätzer

Sei $\vec{X} = (X_1, \dots, X_n)$ eine Stichprobe und sei $\Theta \subseteq \mathbb{R}$ der Parameterraum. Wir suchen für den Parameter $\vartheta \in \Theta$ einen Schätzer T aufgrund unserer Stichprobe.

Schätzer
Ein Schätzer ist eine ZV $T : \Omega \mapsto \mathbb{R}$ von der Form
$T = t(X_1, \dots, X_n), \quad t : \mathbb{R}^n \mapsto \mathbb{R}$
mit Schätzwert $T(\omega) = t(X_1(\omega), \dots, X_n(\omega)) = t(x_1, \dots, x_n)$

Ein Schätzer T ist **erwartungstreu** (unbiased) für ϑ , falls für alle $\vartheta \in \Theta$ gilt:

$$\mathbb{E}_\vartheta[T] = \vartheta$$

⇒ Ist T *erwartungstreu*, so schätzt T im Mittel richtig.

Der **Bias** (erwartete Schätzfehler) von T im Modell \mathbb{P}_ϑ ist:

$$\mathbb{E}_\vartheta[T - \vartheta] = \mathbb{E}_\vartheta[T] - \vartheta$$

⇒ Für *erwartungstreue* Schätzer ist der Bias immer gleich Null.

Der **mittlere quadratische Schätzfehler** (MSE) von T im Modell \mathbb{P}_ϑ ist definiert als:

$$\text{MSE}_\vartheta[T] = \mathbb{E}_\vartheta[(T - \vartheta)^2] = \text{Var}_\vartheta(T) + (\mathbb{E}_\vartheta[T] - \vartheta)^2$$

⇒ Für erwartungstreue Schätzer sind Varianz und MSE dasselbe.

Eine Schätzvariable T heisst **konsistent**, wenn $\text{MSE}_\vartheta[T] \rightarrow 0$ für $n \rightarrow \infty$ gilt. Für genügend grosse n liegen also die Werte von T beliebig nahe am gesuchten Wert ϑ .

Beispiel: Für $\vartheta = \mathbb{E}[X]$ bzw. $\vartheta = \text{Var}[X]$ eignen sich folgende Schätzer:

$$\bar{X}_n := \frac{1}{n} \sum_{i=1}^n X_i \quad \text{und} \quad S_n^2 := \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

\bar{X}_n und S_n^2 heissen (empirisches) *Stichprobenmittel* bzw. *Stichprobenvarianz* der Stichprobe X_1, \dots, X_n u.i.v. und sind *erwartungstreue* Schätzer für den Erwartungswert bzw. Varianz.

8.2 Maximum-Likelihood-Methode

Die Likelihood-Funktion L entspricht der Wahrscheinlichkeit, dass wir die Stichprobe x_1, \dots, x_n erhalten, wenn wir den Parameter mit dem Wert ϑ belegen.

Likelihood Funktion L
$L(x_1, \dots, x_n; \vartheta) := \begin{cases} p_{\vec{X}}(x_1, \dots, x_n; \vartheta) & \text{(diskreter Fall)} \\ f_{\vec{X}}(x_1, \dots, x_n; \vartheta) & \text{(stetiger Fall)} \end{cases}$

Wobei $p_{\vec{X}}(x_1, \dots, x_n; \vartheta) = \mathbb{P}_\vartheta[X_1 = x_1, \dots, X_n = x_n]$ und falls X_i unter \mathbb{P}_ϑ u.i.v., dann sogar: $p_{\vec{X}}(x_1, \dots, x_n; \vartheta) = \prod_{i=1}^n p_X(x_i; \vartheta)$.

Maximum-Likelihood-Schätzer T_{ML}
Der ML-Schätzer T_{ML} maximiert $\vartheta \mapsto L(x_1, \dots, x_n; \vartheta)$:
$T_{ML} = t_{ML}(X_1, \dots, X_n) \in \arg \max_{\vartheta \in \Theta} L(x_1, \dots, x_n; \vartheta)$

Oder anders definiert: $\hat{\vartheta}$ ist der ML-Schätzwert, wenn gilt: $L(x_1, \dots, x_n; \vartheta) \leq L(x_1, \dots, x_n; \hat{\vartheta})$ für alle ϑ .

Anwendung der Methode:

1. Gemeinsame Dichte/Verteilung der ZV finden
 2. Bestimme Log-Likelihood-Funktion $f(\vartheta) := \ln(L(x_1, \dots, x_n; \vartheta))$
 3. $f(\vartheta)$ nach ϑ ableiten
 4. Nullstelle von $f'(\vartheta)$ finden
- ⇒ Unter gefundenem ϑ ist die Likelihood-Funktion maximal.

Beispiel: (Bernoulli-Verteilung) Sei X_1, \dots, X_n u.i.v. $\sim \text{Be}(p)$, also $\vartheta = p$. Ziel: Wir wollen Parameter p schätzen.

1. ⇒ $p_X(x; \vartheta) = \mathbb{P}_\vartheta[X = x] = \vartheta^x \cdot (1 - \vartheta)^{1-x}$ für $x \in \{0, 1\}$
 2. $L(x_1, \dots, x_n; \vartheta) \stackrel{\text{u.i.v.}}{=} \prod_{i=1}^n p_X(x_i; \vartheta) = \vartheta^{\sum_{i=1}^n x_i} \cdot (1 - \vartheta)^{n - \sum_{i=1}^n x_i}$
⇒ $\log L(x_1, \dots, x_n; \vartheta) = \sum_{i=1}^n x_i \log(\vartheta) + (n - \sum_{i=1}^n x_i) \log(1 - \vartheta)$
 3. $\frac{\partial}{\partial \vartheta} \log L(x_1, \dots, x_n; \vartheta) = \frac{1}{\vartheta} \sum_{i=1}^n x_i - \frac{1}{1 - \vartheta} (n - \sum_{i=1}^n x_i)$
 4. Nullstelle bei: $\vartheta = \frac{1}{n} \sum_{i=1}^n x_i$, da $(1 - \vartheta) \sum_{i=1}^n x_i = \vartheta (n - \sum_{i=1}^n x_i)$
- ⇒ Der ML-Schätzer für ϑ bzw. p ist also: $T = \frac{1}{n} \sum_{i=1}^n X_i =: \bar{X}$

9 Testen von Hypothesen

Grundproblem: Entscheidung zwischen zwei konkurrierenden Modellklassen zu treffen.

Die Nullhypothese H_0 und die Alternativhypothese H_A sind zwei Teilmengen $\Theta_0 \subseteq \Theta, \Theta_A \subseteq \Theta$, wobei $\Theta_0 \cap \Theta_A = \emptyset$. Eine Hypothese heisst *einfach*, falls die Teilmenge aus einem einzelnen

Wert besteht (z.B. $\Theta_0 = \{\vartheta_0\}$); sonst heissen sie *zusammengesetzt*. Die Hypothesen lauten also:

- H_0 : "der wahre Parameter ϑ liegt in Θ_0 ", also $\vartheta \in \Theta_0$
 H_A : "der wahre Parameter ϑ liegt in Θ_A ", also $\vartheta \in \Theta_A$

Definition Teststatistik
Man hat eine Abb. $t : \mathbb{R}^n \rightarrow \mathbb{R}, (x_1, \dots, x_n) \mapsto t(x_1, \dots, x_n)$ und einen <i>Verwerfungsbereich</i> $K \subseteq \mathbb{R}$. Die ZV $T := t(X_1, \dots, X_n)$ heisst dann <i>Teststatistik</i> .

- Die Hypothese H_0 wird *verworfen*, falls $T(\omega) \in K$.
- Die Hypothese H_0 wird *akzeptiert*, falls $T(\omega) \notin K$.

Wobei $T(\omega) = t(X_1(\omega), \dots, X_n(\omega))$ gilt.

Es handelt sich um einen Fehler 1. Art , wenn H_0 fälschlicherweise verworfen wird, obwohl sie richtig ist. Wahrscheinlichkeit für einen Fehler 1. Art:
$\mathbb{P}_\vartheta[T \in K], \quad \vartheta \in \Theta_0$
Es handelt sich um einen Fehler 2. Art , wenn H_0 fälschlicherweise akzeptiert wird, obwohl sie falsch ist:
$\mathbb{P}_\vartheta[T \notin K] = 1 - \mathbb{P}_\vartheta[T \in K], \quad \vartheta \in \Theta_A$

Ziel: Fehler 1. und 2. Art möglichst klein, also $\vartheta \mapsto \mathbb{P}_\vartheta[T \in K]$ auf Θ_0 minimieren und auf Θ_A maximieren. Unser primäres Ziel, ist den Fehler 1. Art zu minimieren (die *Macht* zu maximieren). ⇒ Schwieriger die Hypothese zu verwerfen, anstatt zu behalten. Ein seriöser Test wird deshalb als Hypothese immer die Negation der eigentlich gewünschten Aussage benutzen.

Signifikanzniveau und Macht
Ein Test hat <i>Signifikanzniveau</i> $\alpha \in [0, 1]$ falls:
$\forall \vartheta \in \Theta_0 : \mathbb{P}_\vartheta[T \in K] \leq \alpha \iff \sup_{\vartheta \in \Theta_0} \mathbb{P}_\vartheta[T \in K] \leq \alpha$
Die <i>Macht</i> wird definiert als:
$\beta : \Theta_A \mapsto [0, 1], \quad \vartheta \mapsto \beta(\vartheta) := \mathbb{P}_\vartheta[T \in K]$

Ziel: $\vartheta \mapsto \beta(\vartheta)$ möglichst gross, bzw. $1 - \beta(\vartheta)$ möglichst klein.

9.1 Konstruktion von Tests

Ziel: Systematischer Ansatz zum finden von K und T . Sei $\vartheta_0 \in \Theta_0$ und $\vartheta_A \in \Theta_A$. Sei X_1, \dots, X_n diskret oder gemeinsam stetig unter \mathbb{P}_{ϑ_0} und \mathbb{P}_{ϑ_A} , wobei $\vartheta_0 \neq \vartheta_A$.

Likelihood-Quotient
$R(x_1, \dots, x_n; \vartheta_0, \vartheta_A) := \frac{L(x_1, \dots, x_n; \vartheta_A)}{L(x_1, \dots, x_n; \vartheta_0)}$

(Falls $L(x_1, \dots, x_n; \vartheta_0) = 0$ setzen wir $R(x_1, \dots, x_n) = +\infty$.)
 \Rightarrow Wenn $R \gg 1$, so gilt $H_A > H_0$ (H_A ist wahrscheinlicher) und analog wenn $R \ll 1$, so gilt $H_A < H_0$.

Likelihood-Quotient-Test
Der Likelihood-Quotient-Test (LQ-Test) mit Parameter $c \geq 0$ ist definiert durch:
$T = R(x_1, \dots, x_n; \vartheta_0, \vartheta_A) \quad \text{und} \quad K = (c, \infty]$

\Rightarrow Der LQ-Test ist optimal, wenn Hypothese und Alternative beide *einfach* sind, da jeder andere Test mit kleinerem Signifikanzniveau auch eine kleinere Macht hat (*Neyman-Pearson-Lemma*).

9.2 Häufige Fälle

Einen allgemein approximativen Zugang liefert der ZGS. Oft ist ein Schätzer T eine Funktion einer Summe $\sum_{i=1}^n Y_i$, wobei die Y_i u.i.v. sind. Nach dem ZGS ist dann für grosse n $\sum_{i=1}^n Y_i$ approximativ normalverteilt mit $\mu = n \cdot \mathbb{E}_\vartheta[Y_i]$ und $\sigma^2 = n \cdot \text{Var}_\vartheta[Y_i]$. Für normalverteilte Stichproben hat man exakte Aussagen (siehe *z-Test* und *t-Test*).

Approximativer Binomialtest
Annahmen: X_1, \dots, X_n u.i.v. mit $X_i \sim \text{Ber}(p)$ mit $\vartheta = p$ unbekannt. Sei n hinreichend gross.
Hypothesen: <ol style="list-style-type: none"> $H_0 : p = p_0$ gegen $H_A : p \neq p_0$ $H_0 : p \geq p_0$ gegen $H_A : p < p_0$ $H_0 : p \leq p_0$ gegen $H_A : p > p_0$
Testgrösse: $T := \frac{\sum_{i=1}^n X_i - n \cdot p_0}{\sqrt{n \cdot p_0 \cdot (1 - p_0)}} \sim \mathcal{N}(0, 1) \quad \text{nach ZGS}$
Ablehnungskriterium: für H_0 bei Signifikanzniveau α : <ol style="list-style-type: none"> $T > z_{1-\alpha/2}$ $T < z_\alpha$ $T > z_{1-\alpha}$

Herleitung: Wir wissen: $T \sim \mathcal{N}(0, 1)$ unter \mathbb{P}_ϑ . Seien $K_>, K_<$ und K_\neq die Verwerfungsbereiche zu den Fällen 1-3.

- $\alpha = \mathbb{P}_{\vartheta_0}[T \in K_\neq] = \mathbb{P}_{\vartheta_0}[T < -c_\neq] + \mathbb{P}_{\vartheta_0}[T > c_\neq] = \mathbb{P}_{\vartheta_0}[T < -c_\neq] + (1 - \mathbb{P}_{\vartheta_0}[T \leq c_\neq]) = 2 \cdot (1 - \Phi(c_\neq)) \Rightarrow c_\neq = z_{1-\alpha/2}$
- $\alpha = \mathbb{P}_{\vartheta_0}[T \in K_<] = \mathbb{P}_{\vartheta_0}[T < c_<] = \mathbb{P}_{\vartheta_0}[T > -c_<] = 1 - \mathbb{P}_{\vartheta_0}[T \leq -c_<] \Rightarrow c_< = -z_{1-\alpha} = z_\alpha$
- $\alpha = \mathbb{P}_{\vartheta_0}[T \in K_>] = \mathbb{P}_{\vartheta_0}[T > c_>] = 1 - \mathbb{P}_{\vartheta_0}[T \leq c_>] = 1 - \Phi(c_>) \Rightarrow c_> = \Phi^{-1}(1 - \alpha) =: z_{1-\alpha}$

Wichtige Eigenschaften: $\Phi(c) := \mathbb{P}[Z \leq c]$ für $Z \sim \mathcal{N}(0, 1)$,
 $\Phi(-c) = 1 - \Phi(c)$, $\Phi(x)^{-1} =: z_x = -z_{1-x}$ und $t_{m,x} = -t_{m,1-x}$

z-Test (Gausstest)
Annahmen: X_1, \dots, X_n u.i.v. mit $X_i \sim \mathcal{N}(\mu, \sigma^2)$, wobei σ^2 bekannt und μ unbekannt ist. $\Rightarrow \bar{X}_n \sim \mathcal{N}(\mu, \sigma^2/n)$
Hypothesen: <ol style="list-style-type: none"> $H_0 : \mu = \mu_0$ gegen $H_A : \mu \neq \mu_0$ $H_0 : \mu \geq \mu_0$ gegen $H_A : \mu < \mu_0$ $H_0 : \mu \leq \mu_0$ gegen $H_A : \mu > \mu_0$
Testgrösse: $T := \frac{\bar{X}_n - \mu_0}{\sigma} \cdot \sqrt{n} \sim \mathcal{N}(0, 1)$
Ablehnungskriterium: für H_0 bei Signifikanzniveau α : <ol style="list-style-type: none"> $T > z_{1-\alpha/2}$ (für $\alpha = 5\%$ ist $z_{1-\alpha/2} = 1.96$) $T < z_\alpha$ $T > z_{1-\alpha}$

t-Test
Annahmen: X_1, \dots, X_n u.i.v. mit $X_i \sim \mathcal{N}(\mu, \sigma^2)$, σ^2 und μ unbekannt.
Hypothesen: <ol style="list-style-type: none"> $H_0 : \mu = \mu_0$ gegen $H_A : \mu \neq \mu_0$ $H_0 : \mu \geq \mu_0$ gegen $H_A : \mu < \mu_0$ $H_0 : \mu \leq \mu_0$ gegen $H_A : \mu > \mu_0$
Testgrösse: $T := \frac{\bar{X}_n - \mu_0}{S} \cdot \sqrt{n} \sim t_{n-1}$
Ablehnungskriterium: für H_0 bei Signifikanzniveau α : <ol style="list-style-type: none"> $T > t_{n-1, 1-\alpha/2}$ $T < t_{n-1, \alpha}$ $T > t_{n-1, 1-\alpha}$

Zwei-Strichproben-t-Test
Annahmen: X_1, \dots, X_n u.i.v. mit $X_i \sim \mathcal{N}(\mu_X, \sigma^2)$ und Y_1, \dots, Y_m u.i.v. mit $Y_i \sim \mathcal{N}(\mu_Y, \sigma^2)$.
Hypothesen: <ol style="list-style-type: none"> $H_0 : \mu_X = \mu_Y$ gegen $H_A : \mu_X \neq \mu_Y$ $H_0 : \mu_X \geq \mu_Y$ gegen $H_A : \mu_X < \mu_Y$ $H_0 : \mu_X \leq \mu_Y$ gegen $H_A : \mu_X > \mu_Y$
Testgrösse: Falls $m = n$ (<i>gepaarter Zweistichproben-Test</i>), dann sei $Z_i := X_i - Y_i$ und somit $Z_i \sim \mathcal{N}(\mu_X - \mu_Y, 2\sigma^2)$ u.i.v.. Dann führe normal <i>z-Test</i> oder <i>t-Test</i> durch (abhängig ob σ^2 bekannt oder unbekannt). Falls $m \neq n$ (<i>ungepaarter Zweistichproben-Test</i>), so unterscheidet man weiter ob σ^2 bekannt oder unbekannt ist. Falls σ^2 <i>bekannt</i> , so wähle:
$T_1 := \frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{\sigma \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim \mathcal{N}(0, 1)$
Falls σ^2 <i>unbekannt</i> , so wähle:
$T_2 := \frac{(\bar{X}_n - \bar{Y}_m) - (\mu_X - \mu_Y)}{S \sqrt{\frac{1}{n} + \frac{1}{m}}} \sim t_{n+m-2}$
, mit $S^2 = \frac{1}{m+n-2} ((n-1)S_X^2 + (m-1)S_Y^2)$
Ablehnungskriterium: für H_0 bei Signifikanzniveau α : <ol style="list-style-type: none"> $T_1 > z_{1-\alpha/2}$ bzw. $T_2 > t_{m+n-2, 1-\alpha/2}$ $T_1 < z_\alpha$ bzw. $T_2 < t_{m+n-2, \alpha}$ $T_1 > z_{1-\alpha}$ bzw. $T_2 > t_{m+n-2, 1-\alpha}$

9.3 Vorgehen Tests

- Wahl des Modells.
- Formulierung von Hypothese und Alternative.
- Bestimmung der Teststatistik T und der Form des kritischen Bereichs K ; das kann aus einer Herleitung via LQ-Test stammen.
- Festlegung des Niveaus α liefert (die Grenze für) den kritischen Bereich K ; dazu braucht man die Verteilung von T unter \mathbb{P}_ϑ für alle $\vartheta \in \Theta_0$ (exakt oder approximativ).
- Berechnen der Teststatistik $T(\omega)$ aus den Daten; ist $T(\omega) \in K$, so wird die Hypothese H_0 abgelehnt, andernfalls wird die Hypothese H_0 nicht verworfen.

10 Konfidenzintervalle

Das Konfidenzintervall gibt den Bereich an, der mit einer gewissen Wahrscheinlichkeit den Parameter ϑ einer Verteilung einer Zufallsvariablen einschließt. Oftmals verwendet man nur eine Schätzvariavel T und konstruiert ein *symmetrisches Konfidenzintervall* $[T - \delta, T + \delta]$.

Definition Konfidenzintervall
Sei $\alpha \in [0, 1]$. Ein Konfidenzintervall für ϑ mit Niveau $1 - \alpha$ ist ein Zufallsintervall $I = [A, B]$, sodass gilt
$\forall \vartheta \in \Theta \quad \mathbb{P}_{\vartheta}[A \leq \vartheta \leq B] \geq 1 - \alpha$
wobei A und B Zufallsvariablen der Form $A = a(X_1, \dots, X_n), B = b(X_1, \dots, X_n)$ mit $a, b: \mathbb{R}^n \rightarrow \mathbb{R}$ sind.

Beispiel Normalverteilung: (beidseitig) Sei $X_i \sim \mathcal{N}(\mu, \sigma^2)$ und somit ist $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}(\mu, \frac{\sigma^2}{n})$, wobei $\vartheta = \mu$ der unbekannte Parameter und σ^2 bekannt. Dann gilt:

$$\mathbb{P}_{\vartheta}[-z_{1-\frac{\alpha}{2}} \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq z_{1-\frac{\alpha}{2}}] = 1 - \alpha$$

Wobei $z_{1-\frac{\alpha}{2}} = \Phi^{-1}(1 - \alpha/2)$. Wir formen um und erhalten:

$$\mathbb{P}_{\vartheta}[\bar{X}_n - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}] = 1 - \alpha$$

Also erhalten wir für $\vartheta = \mu$ und Niveau $1 - \alpha$ das Konfidenzintervall:

$$I = [\bar{X}_n - z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X}_n + z_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}]$$

Beispiel Geometrische Verteilung: Sei $X_i \sim Geo(\vartheta), T_{ML} = \frac{n}{\sum_{i=1}^n X_i}$ und $\alpha = 0.05 \Rightarrow E[X_i] = 1/\vartheta$ und $\text{Var}[X_i] = (1 - \vartheta)/\vartheta^2$, erhalten wir: $\frac{\sum_{i=1}^n X_i - n/\vartheta}{\sqrt{n(1-\vartheta)/\vartheta^2}} \sim \mathcal{N}(0, 1)$ für $n \rightarrow \infty$ (folgt nach ZGS). Somit:

$$\mathbb{P}_{\vartheta}[-z_{1-\frac{\alpha}{2}} \leq \frac{\sum_{i=1}^n X_i - n/\vartheta}{\sqrt{n(1-\vartheta)/\vartheta^2}} \leq z_{1-\frac{\alpha}{2}}] \geq 1 - \alpha$$

11 Diverses

Die **momenterzeugende Funktion** einer ZV X ist definiert als: $M_X(t) := \mathbb{E}[e^{tX}]$, für $t \in \mathbb{R}$.

Chernoff Schranken
Seien X_1, \dots, X_n u.i.v. ZV, wobei $M_X(t)$ endlich ist für alle $t \in \mathbb{R}$. Sei $S_n := \sum_{i=1}^n X_i$. Dann gilt für jedes $b \in \mathbb{R}$:
$\mathbb{P}[S_n \geq b] \leq \exp \left(\inf_{t \in \mathbb{R}} (n \log M_X(t) - tb) \right)$

Schranke exponentiell in b und in $n \Rightarrow$ sehr gute Abschätzung

Chernoff für Bernoulli-Vert. ZV
Sei nun $X_i \sim Ber(p)$ u.i.v. und somit $S_n \sim Bin(n, p)$. Dann gilt:
$\mathbb{P}[S_n \geq (1 + \delta)\mu_n] \leq \left(\frac{e^{\delta}}{(1 + \delta)^{1+\delta}} \right)^{\mu_n}$

Beispiel: Wir werfen 100-Mal eine Münze und wollen $\mathbb{P}[S_{100} \geq 60]$ berechnen, mit $p_i = 1/2$ für alle i und damit $\mu_n = 50$ und $\delta = 0.2$. Wir erhalten als Abschätzung:

$$\mathbb{P}[S_{100} \geq 60] \leq \left(\frac{e^{0.2}}{1.2^{1.2}} \right)^5 = 0.3909$$

11.1 Anwendung: Simulationsalgorithmus

Satz
Sei F eine stetige und streng monoton wachsende Verteilungsfunktion, mit Umkehrfunktion F^{-1} . Ist $X \sim \mathcal{U}(0, 1)$ und $Y = F^{-1}(X)$, so hat Y gerade die Verteilungsfunktion F .

Beweis: $F_Y(t) = \mathbb{P}[Y \leq t] = \mathbb{P}[F^{-1}(X) \leq t] = \mathbb{P}[X \leq F(t)] = F(t)$
Algorithmus: Man hat einen "Zufallszahlengenerator", d.h. einen deterministischen Algorithmus, der eine Folge (x_1, x_2, \dots) von Zahlen in $[0, 1]$ produziert, die sich in einem gewissen Sinn verhält wie die Realisierung einer Folge von unabhängigen $\mathcal{U}(0, 1)$ -verteilten Zufallsvariablen. In diesem Sinne simuliert also nach obigem Satz F^{-1} (Zufallsgenerator) die Verteilung F .

Beispiel: Um eine Exponentialverteilung mit Parameter λ zu simulieren, nehmen wir die zugehörige Verteilungsfunktion $F(t) = 1 - e^{-\lambda \cdot t}$ für $t \geq 0$. Die Inverse können wir berechnen und erhalten: $F^{-1}(F(t)) = t = -\frac{\log(1-F(t))}{\lambda}$. Mit $X \sim \mathcal{U}(0, 1)$ erhalten wir: $Y := F^{-1}(X) = -\frac{\log(1-X)}{\lambda} \sim \text{Exp}(\lambda)$

11.2 p-Wert

Der *p-Wert* ist Evidenzmaß für die Glaubwürdigkeit der Nullhypothese. Kleiner p-Wert $\Rightarrow H_0$ unwahrscheinlich. Sei X_1, \dots, X_n eine Stichprobe vom Umfang n . Wir wollen eine Hypothese $H_0 : \vartheta = \vartheta_0$ gegen eine Alternative $H_A : \vartheta \in \Theta_A$ testen. Sei $T = t(X_1, \dots, X_n)$ eine Teststatistik und $(T, K_t)_{t \geq 0}$ eine Familie von Tests. Eine Familie von Tests heisst **geordnet** bzgl. T falls $K_t \subset \mathbb{R}$ und $s \leq t \Rightarrow K_t \subset K_s$. Beispiele:

- $K_t = (t, \infty)$ (rechtsseitiger Test)
- $K_t = (-\infty, -t)$ (linksseitiger Test)
- $K_t = (-\infty, -t) \cup (t, \infty)$ (beidseitiger Test)

Definition p-Wert
Sei $H_0 : \vartheta = \vartheta_0$ eine einfache Nullhypothese. Sei $(T, K_t)_{t \geq 0}$ eine geordnete Familie von Tests. Der <i>p-Wert</i> ist eine ZV, mit:
$G : \mathbb{R}_+ \mapsto [0, 1], \quad p\text{-Wert} := G(t) = \mathbb{P}_{\vartheta_0}[T \in K_t]$

Der *p-Wert* hat folgende Eigenschaften:

1. Sei T stetig und $K_t = (t, \infty)$. Dann ist der *p-Wert* unter \mathbb{P}_{ϑ_0} auf $[0, 1]$ gleichverteilt.
2. Für einen *p-Wert* γ gilt, dass alle Tests mit Signifikanzniveau $\alpha > \gamma$ die Nullhypothese verwerfen.

$p\text{-Wert ist klein} \implies H_0 \text{ wird wahrscheinlich verworfen}$
--

Beispiel: Gegeben wir haben einen t-Test mit 8 Freiheitsgraden ausgeführt, wir wollen den p-Wert berechnen. Gegeben sei $T(w) = -3.4$ dann erhalten wir:
 $p\text{-Wert}(w) = P_{H_0}[T < t_0]_{|t_0=T(w)} = P_{H_0}[T < -3.4] = 1 - P_{H_0}[T \leq 3.4]$. Ablesen gibt uns die Schätzung $0.995 \leq P \leq 1$.

11.3 Monte-Carlo Verfahren

Ziel: Integrale approximieren durch die Erzeugung von Zufallszahlen. Nehmen wir an, wir wollen für eine gegebene Funktion $h : [0, 1] \rightarrow \mathbb{R}$ das Integral

$$I := \int_0^1 h(x) dx$$

berechnen. Allgemein auch: $I := \int_{[0,1]^d} h(\underline{x}) d\underline{x}$.

Idee: Fasse I als EW auf; ist nämlich $U \sim \mathcal{U}([0, 1])$, so ist:

$$\mathbb{E}[h(U)] = \int_{-\infty}^{\infty} h(x) f_U(x) dx = \int_0^1 h(x) dx = I$$

Haben wir eine Folge von ZV U_1, U_2, \dots u.i.v. mit $U_i \sim \mathcal{U}([0, 1])$ (mit Zufallsgenerator), so liefert das Gesetz der grossen Zahlen:

$$\overline{h(U_n)} = \frac{1}{n} \sum_{i=1}^n h(U_i) \xrightarrow{n \rightarrow \infty} \mathbb{E}[h(U_1)] = I \quad (\text{f.s.})$$

\Rightarrow Wir erhalten also eine Approximation von I . Der zu erwartende Fehler sinkt mit $\approx \frac{1}{\sqrt{n}}$

11.4 Weitere Verteilungen: Chi- & t-Vert.

Seien $X_i \sim \mathcal{N}(0, 1)$, dann ist die Summe $Y = \sum_{i=1}^n X_i^2 \sim \chi_m^2$ (mit n Freiheitsgraden). Falls $n = 2$, haben wir eine Exponentialverteilung mit Parameter $\frac{1}{2}$.

\mathcal{X}^2 -Verteilung (Chiquadrat-Verteilung)
X_1, \dots, X_n u.i.v. $\sim \mathcal{N}(0, 1)$, so ist $Y := \sum_{i=1}^n X_i^2 \sim \mathcal{X}_n^2$.
$f_Y(t) = \frac{1}{2^{\frac{n}{2}} \Gamma(\frac{n}{2})} t^{\frac{n}{2}-1} e^{-\frac{t}{2}} \quad t > 0$
$\mathbb{E}[\chi_n^2] = n \quad \text{und} \quad \text{Var}[\chi_n^2] = 2n$

Wobei die Gamma-Funktion für $v \geq 0$ definiert ist:

$$\Gamma(v) := \int_0^\infty t^{v-1} \cdot e^{-t} dt$$

Es gilt: $\Gamma(n) = (n - 1)!$ für $n \in \mathbb{N}$ und $\forall r \in \mathbb{R} : r \cdot \Gamma(r) = \Gamma(r + 1)$.

t-Verteilung
$X \sim \mathcal{N}(0, 1)$ und $Y \sim \chi_n^2$ unabh.: $Z := \frac{X}{\sqrt{\frac{1}{n} Y}} \quad t_m$ -verteilt.
$f_Z(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{n\pi} \cdot \Gamma(\frac{n}{2})} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$
$\mathbb{E}[Z] = 0 \text{ für } n > 1 \quad \text{und} \quad \text{Var}[Z] = \frac{n}{n-2} \text{ für } n > 2$

Es gilt: $t_{n,x} \xrightarrow{n \rightarrow \infty} z_x$, mit $z_x := \Phi(x)^{-1}$

11.5 MLE Schätzer

- Bernoulli: $\hat{\lambda} = \hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$
- Exponential: $\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$ und $\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i}$
- Geometrisch: $\hat{p} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}}$
- Binomial: $\hat{\mu} = \frac{1}{N} \frac{\sum_{i=1}^n x_i}{n}$ und $\hat{p} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$
- Normalverteilung: $\hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$ und $\hat{\sigma}^2 = S^2$
- Poisson: $\hat{\lambda} = \hat{\mu} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$
- Uniform: $\hat{b} = \max(x_i), \quad \hat{a} = \min(x_i)$

12 Math Stuff

$$\binom{n}{k} = \frac{n!}{k!(n-k)!} \qquad (x+y)^n = \sum_{k=0}^n \binom{n}{k} x^{n-k} y^k$$

$$ax^2 + bx + c = 0 \quad \Rightarrow \quad x_{1,2} = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

(1) $\cos(z) = \cos(-z)$ und $\sin(-z) = -\sin(z)$
(2) $\cos(\pi - x) = -\cos(x)$ und $\sin(\pi - x) = \sin(x)$
(3) $\sin(z + w) = \sin(z) \cos(w) + \cos(z) \sin(w)$
(4) $\cos(z + w) = \cos(z) \cos(w) - \sin(z) \sin(w)$
(5) $\cos(z)^2 + \sin(z)^2 = 1$
(6) $\sin(2z) = 2 \sin(z) \cos(z)$
(7) $\cos(2z) = \cos(z)^2 - \sin(z)^2$

$$\sin^2(x) = \frac{1}{2}(1 - \cos(2x)) \quad \text{und} \quad \cos^2(x) = \frac{1}{2}(1 + \cos(2x))$$

α	0	30°	45°	60°	90°	120°	150°	180°	270°
	0	$\frac{\pi}{6}$	$\frac{\pi}{4}$	$\frac{\pi}{3}$	$\frac{\pi}{2}$	$\frac{2\pi}{3}$	$\frac{5\pi}{6}$	π	$\frac{3\pi}{2}$
$\sin \alpha$	0	$\frac{1}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{\sqrt{3}}{2}$	1	$\frac{\sqrt{3}}{2}$	$\frac{1}{2}$	0	-1
$\cos \alpha$	1	$\frac{\sqrt{3}}{2}$	$\frac{\sqrt{2}}{2}$	$\frac{1}{2}$	0	$-\frac{1}{2}$	$-\frac{\sqrt{3}}{2}$	-1	0
$\tan \alpha$	0	$\frac{\sqrt{3}}{3}$	1	$\sqrt{3}$	N/A	$-\sqrt{3}$	$-\frac{\sqrt{3}}{3}$	0	N/A

12.1 Typische-Reihen

$\sum_{i=1}^n i = \frac{n(n+1)}{2}$	$\sum_{i=1}^n i^2 = \frac{n(n+1)(2n+1)}{6}$
$\sum_{i=1}^n i^3 = \frac{n^2(n+1)^2}{4}$	$\sum_{i=1}^\infty \frac{1}{n^2} = \frac{\pi^2}{6}$

Die Geometrische Reihe: $\sum_{i=0}^n q^i = \frac{1-q^{n+1}}{1-q}$ konvergiert wenn $|q| < 1$. Dies gilt auch bei $n \rightarrow \infty$:

$$\sum_{i=1}^\infty q^i = 1 + q + q^2 + \dots = \frac{1}{1-q}$$

Die Harmonische Reihe: Die Harmonische Reihe $\sum_{n=1}^\infty \frac{1}{n}$ ist divergent. Die alternierende harmonische Reihe ist jedoch konvergent.

Die Zeta Funktion: Die Riemann-Zeta Funktion $\zeta(s) = \sum_{n=1}^\infty \frac{1}{n^s}$ konvergiert für $s > 1$.

$\mathbf{F(x)}$	$\mathbf{f(x)}$	$\mathbf{f'(x)}$
$\frac{x^{-a+1}}{-a+1}$	$\frac{1}{x^a}$	$\frac{a}{x^{a+1}}$
$\frac{x^{a+1}}{a+1}$	$x^a \ (a \neq 1)$	$a \cdot x^{a-1}$
$\frac{1}{k \ln(a)} a^{kx}$	a^{kx}	$ka^{kx} \ln(a)$
$\ln x $	$\frac{1}{x}$	$-\frac{1}{x^2}$
$\frac{2}{3} x^{3/2}$	\sqrt{x}	$\frac{1}{2\sqrt{x}}$
$-\cos(x)$	$\sin(x)$	$\cos(x)$
$\sin(x)$	$\cos(x)$	$-\sin(x)$
$\frac{1}{2}(x - \frac{1}{2} \sin(2x))$	$\sin^2(x)$	$2 \sin(x) \cos(x)$
$\frac{1}{2}(x + \frac{1}{2} \sin(2x))$	$\cos^2(x)$	$-2 \sin(x) \cos(x)$
$-\ln \cos(x) $	$\tan(x)$	$\frac{1}{\cos^2(x)}$ $1 + \tan^2(x)$
$\cosh(x)$	$\sinh(x)$	$\cosh(x)$
$\log(\cosh(x))$	$\tanh(x)$	$\frac{1}{\cosh^2(x)}$
$\ln \sin(x) $	$\cot(x)$	$-\frac{1}{\sin^2(x)}$
$\frac{1}{c} \cdot e^{cx}$	e^{cx}	$c \cdot e^{cx}$
$x(\ln x - 1)$	$\ln x $	$\frac{1}{x}$
$\frac{1}{2}(\ln(x))^2$	$\frac{\ln(x)}{x}$	$\frac{1-\ln(x)}{x^2}$
$\frac{x}{\ln(a)}(\ln x - 1)$	$\log_a x $	$\frac{1}{\ln(a)x}$

Partielle Integration
$\int_a^b f'(x) \cdot g(x) dx = [f(x) \cdot g(x)]_a^b - \int_a^b f(x) \cdot g'(x) dx$

Substitution
$\int_a^b f(g(x)) \cdot g'(x) dx = \int_{g(a)}^{g(b)} f(u) du$
$\int_{\varphi(U)} f(\vec{v}) d\vec{v} = \int_U f(\varphi(\vec{u})) \cdot \det(D\varphi)(\vec{u}) d\vec{u}$

13 Aufgaben

(HS17, Aufg. 3) Seien X und Y ZV mit:

$$f(x, y) = \begin{cases} \frac{1}{x^2 y^2} & \text{für } x \geq 1, y \geq 1 \\ 0 & \text{sonst} \end{cases}$$

Sei $U := \frac{X}{Y}$ und $V := X \cdot Y$.

- a) Berechne F_U . b) Berechne F_V .
c) Bestimme f_U . d) Bestimme f_V .

- a) Für $u \leq 0$ haben wir $F_U(u) = 0$. Für $u > 1$ erhalten wir: $F_U(u) = \mathbb{P}[\frac{X}{Y} \leq u] = \mathbb{P}[X \leq Y \cdot u] = \int_1^\infty \int_1^{y \cdot u} \frac{1}{x^2 y^2} dx dy = \int_1^\infty \frac{1}{y^2} (1 - \frac{1}{uy}) dy = \int_1^\infty \frac{1}{y^2} - \frac{1}{uy^3} dy = 1 - \frac{1}{2u}$.
Für $0 < u \leq 1$ erhalten wir: $F_U(u) = \int_{1/u}^\infty \int_1^{yu} \frac{1}{x^2 y^2} dx dy = \int_{1/u}^\infty \frac{1}{y^2} (1 - \frac{1}{uy}) dy = \int_{1/u}^\infty \frac{1}{y^2} - \frac{1}{uy^3} dy = u - \frac{u}{2} = \frac{u}{2}$.
- b) Für $v < 1$ ist $F_V(v) = 0$. Für $v \geq 1$: $F_V(v) = \mathbb{P}[X \cdot Y \leq v] = \mathbb{P}[X \leq v/Y] = \int_1^v \int_1^{v/y} \frac{1}{x^2 y^2} dx dy = \int_1^v \frac{1}{y^2} \int_1^{v/y} \frac{1}{x^2} dx dy = \int_1^v \frac{1}{y^2} (1 - \frac{y}{v}) dy = \int_1^v \frac{1}{y^2} - \frac{1}{vy} dy = 1 - \frac{1}{v} (1 + \log(v))$
- c) Für $u > 1$ erhalten wir: $f_U(u) = \frac{dF_U(u)}{du} = \frac{1}{2u^2}$, für $0 < u \leq 1$: $f_U(u) = \frac{1}{2}$ und für $u \leq 0$ haben wir: $f_U(u) = 0$.
- d) Für $v \geq 1$ erhalten wir: $f_V(v) = \frac{dF_V(v)}{dv} = \frac{\log(v)}{v^2}$ und $f_V(v) = 0$ für $v < 1$.

(HS16, Aufg. 3) Seien X und Y zwei unabhängige ZV, beide exponentialverteilt mit Parameter $\lambda > 0$. Sei $U := \frac{X}{X+Y}$ und $V := X + Y$.

- a) Berechne $f_U(u)$ & $F_U(u)$. b) $f_V(v)$ & $F_V(v)$.
c) Bestimme $f_{U,V}$. Sind U und V unabhängig?

- a) U hat nur Werte in $(0, 1)$, also $u \in (0, 1)$. $\mathbb{P}[U \leq u] = \lambda^2 \int_0^\infty e^{-\lambda x} (\int_0^\infty 1_{\{\frac{x}{x+y} \leq u\}} e^{-\lambda y} dy) dx = \lambda^2 \int_0^\infty e^{-\lambda x} (\int_0^\infty 1_{\{\frac{x}{u} - x \leq y\}} e^{-\lambda y} dy) dx = \lambda \int_0^\infty e^{-\lambda x} (\int_{\frac{x}{u}-x}^\infty \lambda e^{-\lambda y} dy) dx = \lambda \int_0^\infty e^{-\lambda x} e^{-\lambda x (\frac{1}{u}-1)} dx = \lambda \int_0^\infty e^{-\frac{\lambda x}{u}} dx = u$.
Somit ist $U \sim \mathcal{U}(0, 1)$ und darum: $f_U(u) = 1_{\{0 \leq u \leq 1\}}$.

- b) $\mathbb{P}[V \leq v] = \lambda^2 \int_0^\infty e^{-\lambda x} (\int_0^\infty 1_{\{x+y \leq v\}} e^{-\lambda y} dy) dx = \lambda^2 \int_0^\infty e^{-\lambda x} \cdot 1_{\{x \leq v\}} (\int_0^{v-x} 1_{\{y \leq v-x\}} e^{-\lambda y} dy) dx = \lambda \int_0^v e^{-\lambda x} (\int_0^{v-x} \lambda e^{-\lambda y} dy) dx = \lambda \int_0^v e^{-\lambda x} (1 - e^{-\lambda(v-x)}) dx = 1 - e^{-\lambda v} - \lambda v e^{-\lambda v}$ für $v > 0$ und $F_V(v) = 0$ für $v \leq 0$.
Und die Dichte: $f_V(v) = \frac{dF_V(v)}{dv} = \lambda^2 v e^{-\lambda v} \cdot 1_{\{v > 0\}}$.
- c) $\mathbb{P}[U \leq u, V \leq v] = \lambda^2 \int_0^\infty e^{-\lambda x} (\int_0^\infty 1_{\{\frac{x}{x+y} \leq u, x+y \leq v\}} e^{-\lambda y} dy) dx = \lambda^2 \int_0^\infty e^{-\lambda x} (\int_0^\infty 1_{\{x(\frac{1}{u}-1) \leq y \leq v-x, x \leq uv\}} e^{-\lambda y} dy) dx = \lambda \int_0^{uv} e^{-\lambda x} (\int_{x(\frac{1}{u}-1)}^{v-x} \lambda e^{-\lambda y} dy) dx = \lambda \int_0^{uv} e^{-\lambda x} (e^{-\lambda x (\frac{1}{u}-1)} - e^{-\lambda(v-x)}) dx = \lambda \int_0^{uv} (e^{-\lambda \frac{x}{u}} - e^{-\lambda v}) dx = u(1 - e^{-\lambda v} - \lambda v e^{-\lambda v})$.
Somit: $F_{U,V}(u, v) = F_U(u) \cdot F_V(v) \Rightarrow U$ und V sind unabhängig. Und für die Dichte gilt somit: $f_{U,V} = f_U(u) \cdot f_V(v) = \lambda^2 v e^{-\lambda v} \cdot 1_{\{0 \leq u \leq 1, v > 0\}}$

(HS20) Seien U_1, U_2, U_3 u.i.v mit $U_i \sim \mathcal{U}([0, 1])$. Sei $L := \min(U_1, U_2, U_3)$ und $M := \max(U_1, U_2, U_3)$.
a) Berechne $f_M(m)$. b) Bestimme $f_{M,L}(m, l)$.
c) Berechne $f_{L|M}(l, m)$.

- a) $F_M(m) = \mathbb{P}[U_1 \leq m, U_2 \leq m, U_3 \leq m] \stackrel{\text{unab.}}{=} \prod_{i=1}^3 \mathbb{P}[U_i \leq m] \stackrel{\text{i.d.}}{=} \begin{cases} 1 & m \geq 1 \\ m^3 & 0 \leq m \leq 1 \\ 0 & \text{sonst} \end{cases}$
 $\Rightarrow f_M(m) = 3m^2 \cdot 1_{\{m \in [0, 1]\}}$
- b) $\mathbb{P}[M \leq m, L \leq l] = \mathbb{P}[M \leq m] - \mathbb{P}[M < m, L > l] = m^3 - \mathbb{P}[l < U_1 < m, l < U_2 < m, l < U_3 < m] = m^3 - (\mathbb{P}[l < U_1 < m])^3 = m^3 - (m-l)^3$, für $0 \leq l \leq m \leq 1$.
 $\Rightarrow f_{M,L}(m, l) = 6(m-l) \cdot 1_{\{0 \leq l \leq m \leq 1\}}$
- c) $f_{L|M}(l, m) = \frac{f_{M,L}(m, l)}{f_M(m)} = \frac{6(m-l)}{3m^2} \cdot 1_{\{0 \leq l \leq m \leq 1\}} = 2 \frac{m-l}{m^2} \cdot 1_{\{0 \leq l \leq m \leq 1\}}$

(HS20) Würfel mit sechs Seiten, vermutlich gezinkt (landet eher auf der 6). Experiment: Zehn Würfe (unabhängig). Sei $X_i = 1$, wenn der i -te Wurf eine sechs ist, und sonst gleich null. Wir wissen: $\sum_{i=1}^n 0X_i = 4$ (aus Tabelle).
a) Führe einen Test mit $\alpha = 1\%$ und prüfe ob gezinkt
b) Finde den P-Wert.

- a) i. **Modell:** $X_i \stackrel{i.i.d.}{\sim} \text{Bernoulli}(p)$, p unbekannt.
ii. **Nullhypothese:** $H_0 : p = p_0 = 1/6$
iii. **Alternativhypothese:** $H_A : p > 1/6$
iv. **Teststatistik:** $T := \sum_{i=1}^{10} X_i$
v. **Vert. Testst. unter H_0 :** $T \sim \text{Bin}(10, 1/6)$
vi. **Verwerfungsbereich:** Wir möchten alle $k \in \{0, \dots, 9\}$, sodass: $\mathbb{P}_{p_0}[T > k] \leq 0,01 \iff \mathbb{P}_{p_0}[T \leq k] > 0,99$.
 $\Rightarrow K = \{6, 7, 8, 9\}$ (Werte aus Tabelle)
vii. **Beob. Werte der Teststat.:** $T(x_1, \dots, x_{10}) = 4$
viii. **Testentscheid:** $T(\omega) = 4 \notin \{6, 7, 8, 9\} \Rightarrow$ Wir werfen H_0 nicht.
- b) $\mathbb{P}_{p_0}[T \geq 4] = 1 - \mathbb{P}_{p_0}[T < 4] = 1 - 0,93 = 0,07$

((FS21, Aufg. 4, t-Test) Gegeben sind 9 unabhängige Temperaturmessung die $\mathcal{N}(\mu, \sigma^2)$ -verteilte ZV sind. Wir möchten auf einem 5%-Niveau testen, ob die erwartete tägliche Höchsttemperatur im Vergleich zum Wert zum Vorjahr (22 Grad) gesunken ist. Gegeben: $\bar{X}_9 = 18,6$ und $S_9 = 3$.
a) Führe einen Test durch b) bestimme P-Wert

- a) i. **Modell:** X_1, \dots, X_9 i.i.d. $\sim \mathcal{N}(\mu, \sigma^2)$ unter \mathbb{P}_θ , wobei $\theta = (\mu, \sigma^2)$ unbekannt.
ii. **Hypothesen:** $H_0 : \mu = \mu_0 = 22$ und $H_A : \mu < \mu_0$
iii. **Teststatistik & Verteilung unter H_0 :** Da μ und σ^2 unbekannt, führen wir einen t-Test durch:

$$T = \frac{\bar{X}_9 - \mu_0}{S_9/\sqrt{9}} \sim t_8$$

- iv. **Verwerfungsbereich:** Nach der Alternative hat der kritische Bereich die Form $K_< = (-\infty, c_<)$ für ein zu bestimmendes $c_<$. Für $\alpha = 0,05$ wählen wir $c_<$ so, dass: $\alpha = \mathbb{P}[T < c_<] \Rightarrow c_< = t_{n-1, \alpha} = -t_{n-1, 1-\alpha} = -t_{8, 0,95} = -1,86 \Rightarrow K_< = (-\infty, -1,86)$.
v. **Wert der Teststatistik:** Durch einsetzen:

$$T(\omega) = t(x_1, \dots, x_9) = \frac{\bar{X}_9 - \mu_0}{S_9/\sqrt{9}} = \frac{18,6 - 22}{3/3} = -3,4$$

- vi. **Testentscheid:** Wegen $T \in (-\infty, -1,86) = K_<$ verwerfen wir die Hypothese und nehmen die Alternative an. \Rightarrow Daten sprechen dafür, dass die Temperatur tatsächlich gesunken ist.
- b) $p\text{-Wert}(\omega) = \mathbb{P}_{H_0}[T < -3,4] = 1 - \mathbb{P}_{H_0}[T < 3,4]$. Wegen $t_{8, 0,995} = 0,355 < 3,4$, folgt: $0 \leq p\text{-Wert}(\omega) \leq 0,005$.

(FS21, Aufg. 2) Seien X und Y zwei unabh. ZV mit $X \sim Poi(\lambda)$ und $Y \sim Poi(\mu)$, wobei $\lambda, \mu > 0$.

- Zeige, dass $X + Y \sim Poi(\lambda + \mu)$
- Zeige, dass $X|X + Y = n \sim Bin(n, \frac{\lambda}{\lambda + \mu})$
- Bestimme $\mathbb{P}[X + Y = n | Y = l]$ für alle n, l

- $p_{X+Y}(k) = p_X(k) * p_Y(k) \stackrel{unabh.}{=} \sum_{x=0}^k p_X(x) \cdot p_Y(k-x) = \sum_{x=0}^k \frac{\lambda^x}{x!} e^{-\lambda} \cdot \frac{\mu^{k-x}}{(k-x)!} e^{-\mu} = \sum_{x=0}^k \frac{\lambda^x \mu^{k-x}}{x!(k-x)!} e^{-(\lambda+\mu)} = e^{-(\lambda+\mu)} \frac{1}{k!} \sum_{x=0}^k \frac{k!}{x!(k-x)!} \lambda^x \mu^{k-x} \stackrel{Bin.Satz}{=} e^{-(\lambda+\mu)} \frac{(\lambda+\mu)^k}{k!}$
- $\mathbb{P}[X = k | X + Y = n] = \frac{\mathbb{P}[X=k, X+Y=n]}{\mathbb{P}[X+Y=n]} = \frac{\mathbb{P}[X=k, Y=n-k]}{\mathbb{P}[X+Y=n]} = \frac{\frac{\lambda^k}{k!} e^{-\lambda} \cdot \frac{\mu^{n-k}}{(n-k)!} e^{-\mu}}{\frac{(\lambda+\mu)^n}{n!} e^{-(\lambda+\mu)}} = \frac{n!}{k!(n-k)!} \cdot \frac{\lambda^k \mu^{n-k}}{(\lambda+\mu)^n} = \binom{n}{k} \frac{\lambda^k \mu^{n-k}}{(\lambda+\mu)^n} = \binom{n}{k} \left(\frac{\lambda}{\lambda+\mu}\right)^k \left(\frac{\mu}{\lambda+\mu}\right)^{n-k}$
- Für $n \notin \mathbb{N}$ oder $l \notin \mathbb{N}$ oder $l, n \in \mathbb{N}, l > n$ ist $\mathbb{P}[X + Y = n | Y = l] = 0$ (trivial).
Für den Fall $l, n \in \mathbb{N}, l \leq n$: $\mathbb{P}[X + Y = n | Y = l] = \frac{\mathbb{P}[X+Y=n, Y=l]}{\mathbb{P}[Y=l]} = \frac{\mathbb{P}[X=n-l, Y=l]}{\mathbb{P}[Y=l]} = \frac{\frac{\lambda^{n-l}}{(n-l)!} e^{-\lambda} \cdot \frac{\mu^l}{l!} e^{-\mu}}{\frac{\mu^n}{n!} e^{-\mu}} = \frac{n!}{(n-l)! l!} \frac{\lambda^{n-l} \mu^l}{\mu^n} = \frac{n!}{(n-l)! l!} \left(\frac{\lambda}{\mu}\right)^{n-l}$


(FS20, Aufg. 2) Zeige, dass für eine diskrete ZV Z mit Werten in \mathbb{N} gilt: $\exists q \in (0, 1) : Z \sim Geo(q) \iff \mathbb{P}[Z > n] = \mathbb{P}[Z > n + k | Z > k], n, k \geq 1$

- (\Rightarrow) : Sei $Z \sim Geo(q), q \in [0, 1]$. Dann gilt: $\mathbb{P}[Z > k] = (1 - q)^k$ und somit für alle $k, n \in \mathbb{N}$, dass:
 $\mathbb{P}[Z > n + k | Z > k] = \frac{\mathbb{P}[Z > n + k, Z > k]}{\mathbb{P}[Z > k]} = \frac{\mathbb{P}[Z > n + k]}{\mathbb{P}[Z > k]} = \frac{(1-q)^{n+k}}{(1-q)^k} = (1-q)^n = \mathbb{P}[Z > n]$
- (\Leftarrow) : Sei nun $\mathbb{P}[Z > n + k | Z > k] = \mathbb{P}[Z > n]$ für $n, k \in \mathbb{N}$. Dann gilt:
 $\mathbb{P}[Z > n] = \mathbb{P}[Z > n + k | Z > k] = \frac{\mathbb{P}[Z > n + k]}{\mathbb{P}[Z > k]}$. Nun sei $f(n) := \mathbb{P}[Z > n]$. Es gilt also: $\forall n, k \in \mathbb{N} : f(n) \cdot f(k) = f(n + k)$. Wegen $f(n + 1) = f(n) f(1)$ folgt sofort durch Iteration, dass $f(n) = a^n$ mit $a = f(1)$ und damit: $\mathbb{P}[Z = n] = \mathbb{P}[Z > n - 1] - \mathbb{P}[Z > n] = f(n - 1) - f(n) = (1 - a) a^{n-1}$. Schliesslich ist $a = f(1) = \mathbb{P}[Z > 1] \in [0, 1]$, also auch $q = 1 - a \in [0, 1]$ und damit $Z \sim Geo(q)$.

(FS20, Aufg. 3) Man wählt zufällig uniform verteilt einen Punkt $A = (X, Y)$ in dem Gebiet $D = \{(x, y) \in \mathbb{R} : 1/2 \leq \max(|x|, |y|) \leq 1\}$. Somit ist:

$$f_{X,Y}(x, y) = \begin{cases} c & \text{falls } 1/2 \leq |x| \leq 1 \text{ und } |y| \leq 1 \\ c & \text{falls } 1/2 \leq |y| \leq 1 \text{ und } |x| \leq 1/2 \\ 0 & \text{sonst} \end{cases}$$

Sei $V = (2 \max(|X|, |Y|))^2$ die Fläche des achsenparallelen Quadrates, welches seinen Mittelpunkt im Ursprung $O = (0, 0)$ hat und bei welchem der Punkt A auf einer der Seitenkanten liegt. Sei weiter σ der Abstand vom Punkt A zum Punkt $B = (2, 0)$. (a) Bestimme $c, f_X(x)$ und $f_Y(y)$ (b) Finde $\mathbb{E}[X^2]$ & $\mathbb{E}[\sigma^2]$ (c) Berechne $f_V(v)$ & $\mathbb{E}[V]$



- Zuerst berechnen wir c : $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{X,Y}(x, y) dx dy = \int_{-1}^1 \int_{-1}^1 c dx dy - \int_{-1/2}^{1/2} \int_{-1/2}^{1/2} c dx dy = 4c - c = 3c \stackrel{!}{=} 1 \Rightarrow c = \frac{1}{3}$ Für die Dichte erhalten wir:
 $f_X(x) = \begin{cases} \int_{-1}^{-1/2} c dy + \int_{1/2}^1 c dy = c = \frac{1}{3} & \text{falls } |x| \leq \frac{1}{2} \\ \int_{-1}^1 c dy = 2c = \frac{2}{3} & \text{falls } \frac{1}{2} \leq |x| \leq 1 \\ 0 & \text{sonst} \end{cases}$
Zudem gilt: $f_X(k) = f_Y(k)$ aus Symmetrie gründen.

- $\mathbb{E}[X^2] = \int_{-1}^1 x^2 \cdot f_X(x) dx = 2 \cdot \left(\int_0^{1/2} x^2 \cdot \frac{1}{3} dx + \int_{1/2}^1 x^2 \cdot \frac{2}{3} dx \right) = 2 \cdot \left(\left[\frac{1}{9} x^3 \right]_0^{1/2} + \left[\frac{2}{9} x^3 \right]_{1/2}^1 \right) = 2 \cdot \left(\frac{1}{72} - \frac{2}{72} + \frac{2}{9} \right) = \frac{5}{12}$
Zudem gilt: $\mathbb{E}[X^2] = \mathbb{E}[Y^2]$ aus Symmetrie gründen.
 $\mathbb{E}[\sigma^2] = \mathbb{E}[(X - 2)^2 + Y^2] = \mathbb{E}[X^2 - 4X + 4 + Y^2] = \mathbb{E}[X^2] - 4 \cdot \mathbb{E}[X] + 4 + \mathbb{E}[Y^2] = \frac{5}{12} - 4 \cdot 0 + 4 + \frac{5}{12} = \frac{29}{6}$
- Wir sehen, dass $1 \leq V \leq 4$. Sei $S := 2 \max(|X|, |Y|)$ (Seitenlänge von V). Nun gilt für $v \in [1, 4]$:
 $\mathbb{P}[V \leq v] = \mathbb{P}[S \leq \sqrt{v}] = \mathbb{P}[\max(|X|, |Y|) \leq \sqrt{v}/2] = \mathbb{P}[|X| \leq \sqrt{v}/2, |Y| \leq \sqrt{v}/2] = \frac{1}{3} \int_{|y| \leq 1} \int_{1/2 \leq |x| \leq 1} 1_{\{|x| \leq \sqrt{v}/2, |y| \leq \sqrt{v}/2\}} dx dy + \frac{1}{3} \int_{|x| \leq 1/2} \int_{1/2 \leq |y| \leq 1} 1_{\{|x| \leq \sqrt{v}/2, |y| \leq \sqrt{v}/2\}} dy dx = \frac{1}{3} \sqrt{v} (\sqrt{v} - 1) + \frac{1}{3} (\sqrt{v} - 1) = \frac{1}{3} (v - 1)$
Somit ist: $f_V(v) = 1/3$ für $v \in [0, 4]$ und 0 sonst.
Somit erhalten wir: $\mathbb{E}[V] = \frac{1}{3} \int_1^4 v dv = \frac{5}{2}$.

(HS19, A3) Sei $P \sim \mathcal{U}(0, 1)$ und $H | P \sim \mathcal{U}(0, p)$.

- Bestimme $f_{H,P}$
- Bestimme f_H
- Bestimme $\mathbb{E}[H], \mathbb{E}[P]$
- Bestimme $cov(H, P)$

- Wir wissen: $f_{H|P}(h | p) = \frac{1}{p} \cdot 1_{\{h \in (0, p)\}}$
 $\Rightarrow f_{H,P}(h, p) = f_{H|P}(h | p) \cdot f_P(p) = \frac{1}{p} \cdot 1_{\{h \in (0, p) \wedge p \in [0, 1]\}}$
- $f_H(h) = \int_{-\infty}^{\infty} f_{H,P}(h, p) dp = \int_0^1 \frac{1}{p} \cdot 1_{\{h \in (0, p)\}} dp = \int_h^1 \frac{1}{p} dp = -\ln(h)$, für $0 \leq h \leq 1$.
- $\mathbb{E}[H] = -\int_0^1 h \log h dh = \left[-\frac{h^2}{2} \log h \right]_0^1 + \int_0^1 \frac{h^2}{2} \frac{1}{h} dh = 1/4$. Zudem ist $\mathbb{E}[P] = \frac{1}{2}$ und somit $\mathbb{E}[H] = \frac{\mathbb{E}[P]}{2}$.
- $\mathbb{E}[P \cdot H] = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} p \cdot h \cdot f_{P,H}(p, h) dp dh = \int_0^1 \int_0^p h dh dp = \int_0^1 \frac{p^2}{2} dp = \frac{1}{6}$.
 $\Rightarrow Cov(P, H) = \mathbb{E}[PH] - \mathbb{E}[P]\mathbb{E}[H] = \frac{1}{6} - \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{24}$. Somit sind P und H abhängig!

(FS19, A2) Zwei Halbleiter parallel geschaltet, Kontrolllicht leuchtet auf, falls einer der beiden ausfällt. Sei $X_1, X_2 \sim Exp(1/60)$ die Lebensdauer der beiden Halbleiter. Sei Z die Zeit bis die Kontrollleuchte aufleuchtet.

- Finde Verteilung von Z
- Finde W'keit, dass Bauteil ≥ 35 Mal in 3 Jahren ersetzt wird (wird ersetzt falls Kontroll. leuchtet)

- Sei $T :=$ Zeit bis Kontrolllicht leuchtet.
 $\Rightarrow F_T(t) = \mathbb{P}[T \leq t] = \mathbb{P}[\min(X_1, X_2) \leq t] = 1 - \mathbb{P}[\min(X_1, X_2) > t] = 1 - \mathbb{P}[X_1 > t] \cdot \mathbb{P}[X_2 > t] = 1 - e^{-2/60} \Rightarrow T \sim Exp(1/30)$
- Nach einer Zeit T_i (in Tagen) wird das erste Bauteil ersetzt. Es gilt $T_i i.i.d. \sim Exp(1/30)$. Sei $S := \sum_{i=1}^{36} T_i$. Wir wollen $\mathbb{P}[S < 3 \cdot 365]$ finden. Es gilt: $\mathbb{E}[S] = 36 \cdot \mathbb{E}[T_i] = 36 \cdot 30 = 1080$ und $\text{Var}[S] = 36 \cdot \text{Var}[T_i] = 36 \cdot 30^2 = 32400$. Nach dem ZGS folgt: $\mathbb{P}[S < 3 \cdot 365] = \mathbb{P}\left[\frac{S - \mathbb{E}[S]}{\sqrt{\text{Var}[S]}} \leq \frac{3 \cdot 365 - \mathbb{E}[S]}{\sqrt{\text{Var}[S]}}\right] = \mathbb{P}\left[\frac{S - 1080}{180} \leq \frac{15}{180}\right] = \Phi(1/12) = \Phi(0,08) = 53.19\%$